

PROJET FIL ROUGE — DATA ANALYST

Analyse du bien-être sur Terre

World Happiness Report

Rapport final

De l'exploration des données au tableau de bord

2 363 observations · 165 pays · 2005 – 2023

Source : World Happiness Report 2024, Gallup World Poll

Sana Oubella · Seydou Dabo · Leodomir Hakizimana · Raphaela Essombono Nkoudou

Promotion 2026 · Date : [Août 2026]

Sommaire

Sommaire.....	2
Résumé	4
1. Introduction	5
1.1 Contexte.....	5
1.2 Objectifs.....	5
2. Compréhension et exploration des données.....	7
2.1 Source et cadre	7
2.2 Valeurs manquantes	7
2.3 Distributions et valeurs atypiques	8
3. Pre-processing et feature engineering	9
3.1 Imputation	9
3.2 Normalisation et standardisation	9
3.3 Variables créées	10
4. Analyses et résultats	11
4.1 Distribution de la cible et évolution temporelle.....	11
4.2 Hiérarchie des facteurs	11
4.3 Classement des pays.....	13
4.4 Écarts au modèle	13
5. Restitution.....	14
5.1 Tableau de bord Power BI.....	14
5.2 Référentiel géographique	Erreur ! Signet non défini.
6. Difficultés rencontrées.....	15
6.1 Verrou principal	15
6.2 Difficultés liées aux données	15
6.3 Difficultés de compétences.....	15
6.4 Difficultés techniques et organisationnelles.....	15
6.5 Écart au prévisionnel	16
7. Bilan par objectif.....	17
7.1 Ce que le projet établit	17
7.2 Ce que le projet n'établit pas.....	17
8. Suite du projet	18
9. Conclusion.....	19
Bibliographie.....	20
Annexes.....	21
Annexe A — Description des fichiers.....	21
Annexe B — Structure du notebook.....	21
Annexe C — Dictionnaire des colonnes du fichier nettoyé	21

Annexe D — Outils et environnement	21
Annexe E — Recours à des outils d'assistance	21

Résumé

Ce projet porte sur l'analyse du bien-être déclaré dans 165 pays entre 2005 et 2023, à partir des données du World Happiness Report. Il poursuit une question simple à formuler et difficile à trancher : pourquoi certains pays se déclarent-ils plus heureux que d'autres, et la richesse suffit-elle à l'expliquer ?

Le travail s'est déroulé en trois temps. L'exploration a révélé un panel non équilibré, comportant 1,49 % de valeurs manquantes et une forte hétérogénéité d'échelles entre variables. Le pre-processing a produit un jeu de données complet de 31 colonnes, sans suppression d'aucune observation, en s'appuyant sur une imputation respectant la structure temporelle de chaque pays. La restitution a pris la forme d'un tableau de bord Power BI interactif, dont la dernière page isole les pays qui s'écartent de ce que leurs conditions économiques laissent attendre.

Le principal résultat est double. D'une part, trois facteurs — le produit intérieur brut par habitant, le soutien social et l'espérance de vie en bonne santé — suffisent à expliquer l'essentiel des écarts observés, avec des corrélations comprises entre +0,71 et +0,78. D'autre part, la dispersion résiduelle reste substantielle : à niveau de développement équivalent, plus d'un point d'écart subsiste entre certains pays. Le Costa Rica illustre cet écart positif, le Botswana l'écart inverse. C'est dans cette part inexpliquée que se logent les facteurs culturels et institutionnels que les six déterminants du rapport ne captent pas.

1. Introduction

1.1 Contexte

Depuis 2012, le World Happiness Report publie un classement mondial du bien-être fondé sur les enquêtes du Gallup World Poll. Sa particularité est de ne pas mesurer la richesse d'un pays, mais la façon dont ses habitants évaluent leur propre vie sur une échelle de 0 à 10, dite échelle de Cantril. Ce score déclaratif est mis en regard de six déterminants : le produit intérieur brut par habitant, le soutien social, l'espérance de vie en bonne santé, la liberté de choix, la générosité et la perception de la corruption.

L'intérêt du jeu de données tient au décalage récurrent entre richesse et bien-être déclaré. Certains pays très riches se classent en deçà de pays bien plus pauvres, et inversement. Comprendre quelles combinaisons de facteurs expliquent ces écarts constitue le cœur du projet.

Enjeu métier

Les indicateurs de bien-être sont aujourd'hui mobilisés bien au-delà du champ académique : organisations internationales pour l'évaluation des politiques publiques, collectivités pour le pilotage de leur attractivité, directions des ressources humaines pour les politiques de qualité de vie au travail. Restituer un indicateur composite complexe à un public non technique, sans en trahir la construction, est une compétence directement transposable en entreprise.

Enjeu technique

Le jeu de données est un panel non équilibré croisant pays et années. Cette structure impose des traitements spécifiques, notamment pour l'imputation, qui doit respecter la trajectoire propre à chaque pays plutôt que d'écraser l'information par des statistiques globales. Il présente en outre une forte hétérogénéité d'échelles, ce qui rend indispensable une étape de normalisation avant toute visualisation comparative.

Enjeu économique

Le rapport est régulièrement cité pour arbitrer entre croissance économique et politiques sociales. Quantifier la part de variance du bien-être expliquée par le PIB relativement à celle expliquée par le soutien social a une portée directe en matière de priorisation des dépenses publiques. Le jeu de données étant public et gratuit, le coût de production de l'analyse se limite au temps d'étude.

1.2 Objectifs

N°	Objectif	Livrable associé
1	Constituer un jeu de données propre, complet et documenté	World-happiness-report-cleaned.csv, rapport d'exploration
2	Identifier et hiérarchiser les facteurs associés au bien-être	Analyses de corrélation, score composite
3	Mettre en évidence les dynamiques temporelles et les ruptures	Variable life_ladder_yoy, courbes d'évolution
4	Restituer l'ensemble sous une forme lisible par un non-spécialiste	Tableau de bord Power BI à quatre pages

Aucun membre du groupe ne disposait, au démarrage, d'une expertise préalable sur les indicateurs de bien-être ou sur l'économie du bonheur : la compréhension du domaine s'est construite à partir de la documentation méthodologique du World Happiness Report, qui décrit précisément la provenance et la construction de chaque variable. Aucun expert métier n'a été sollicité directement ; les annexes statistiques du rapport et les publications qui l'accompagnent ont tenu lieu de référence. Le jeu de données étant l'un

des plus utilisés de la communauté Kaggle, de nombreuses analyses publiques existent ; elles se concentrent presque toutes sur le classement et les corrélations, ce qui a conforté le choix de centrer ce projet sur les écarts au modèle plutôt que sur une redite du palmarès.

2. Compréhension et exploration des données

2.1 Source et cadre

Le fichier World-happiness-report-updated_2024.csv est publié dans le cadre du World Happiness Report 2024 et diffusé librement sur Kaggle ainsi que sur le site officiel worldhappiness.report. Les données sont produites par le Gallup World Poll et enrichies de sources tierces publiques : Banque mondiale pour le PIB, Organisation mondiale de la santé pour l'espérance de vie. Aucune restriction d'usage n'y est attachée pour un projet pédagogique. Le fichier est encodé en latin-1, ce qui doit être précisé explicitement à la lecture, faute de quoi certains noms de pays sont corrompus.

Caractéristique	Valeur
Volumétrie	2 363 lignes × 11 colonnes
Pays	165
Période	2005 à 2023, soit 19 années
Granularité	1 ligne = 1 pays × 1 année
Clé primaire	(Country name, year) — 0 doublon strict, 0 doublon sur la clé
Valeurs manquantes	386 cellules, soit 1,49 % du total

Le panel est non équilibré : le nombre d'observations par pays varie de 1 pour Cuba à 18 pour l'Argentine, pour une médiane de 16. La couverture s'étoffe progressivement — 27 pays en 2005, 89 en 2006, puis un plateau compris entre 116 et 147 pays à partir de 2007. Cette montée en charge a une conséquence directe sur l'interprétation, détaillée en section 4.1.

2.2 Valeurs manquantes




Figure 1 — Taux de valeurs manquantes par variable et localisation

Le taux global de valeurs manquantes est faible, mais leur répartition est très inégale. La variable cible Life Ladder et les deux identifiants sont intégralement renseignés : aucune observation n'est donc à écarter pour cause de cible absente. Perceptions of corruption concentre en revanche un tiers des manquants, avec 5,29 % de la colonne. Ce n'est pas fortuit : la question porte sur un sujet politiquement sensible et n'est pas posée, ou reste sans réponse exploitable, dans certains pays. Le mécanisme de manquant n'est donc pas aléatoire, et l'imputation de cette colonne doit être interprétée avec prudence.

La visualisation de droite montre que les manquants se regroupent par blocs horizontaux, c'est-à-dire par pays, et non de façon diffuse. Un pays donné tend à être absent d'une variable sur plusieurs années consécutives. Ce constat a directement orienté la stratégie d'imputation vers une approche intra-pays.

2.3 Distributions et valeurs atypiques

Variable	Min	Médiane	Max	Skewness	Outliers (IQR)
Life Ladder	1,281	5,449	8,019	-0,05	2 (0,08 %)
Log GDP per capita	5,527	9,503	11,676	-0,34	1 (0,04 %)
Social support	0,228	0,834	0,987	-1,11	48 (2,03 %)
Healthy life expectancy	6,720	65,100	74,600	-1,13	20 (0,85 %)
Freedom to make life choices	0,228	0,771	0,985	-0,70	16 (0,68 %)
Generosity	-0,340	-0,022	0,700	+0,77	39 (1,65 %)
Perceptions of corruption	0,035	0,798	0,983	-1,49	194 (8,21 %)
Positive affect	0,179	0,663	0,884	-0,46	9 (0,38 %)
Negative affect	0,083	0,262	0,705	+0,70	31 (1,31 %)

Deux enseignements ressortent. Le premier concerne les échelles : l'espérance de vie en bonne santé s'exprime en années et couvre l'intervalle [6,7 ; 74,6], le log-PIB varie entre 5,5 et 11,7, tandis que les six autres indicateurs sont des proportions bornées dans [0 ; 1]. Un facteur cent sépare les amplitudes. Sans mise à l'échelle, l'espérance de vie écraserait mécaniquement toutes les autres variables dans un graphique radar, une heatmap ou tout algorithme fondé sur des distances.

Le second concerne les valeurs atypiques. Perceptions of corruption en compte 194, soit 8,21 %. Ce taux traduit la forme très asymétrique de sa distribution plutôt que des erreurs de mesure : la méthode de l'écart interquartile suppose une distribution approximativement symétrique et sur-signe mécaniquement les distributions fortement dissymétriques.

Décision : conserver les valeurs atypiques

Les valeurs extrêmes de ce jeu de données ne sont pas des artefacts mais des observations réelles. L'Afghanistan à 1,45 sur l'échelle de Cantril en 2023, ou le Burundi sur le soutien social, décrivent des situations authentiques. Les supprimer reviendrait à retirer de l'analyse précisément les pays les plus intéressants à comparer, et biaiserait tout classement.

Exception : une anomalie avérée

Un seul cas relève de l'erreur de saisie. L'espérance de vie en bonne santé d'Haïti est renseignée à 6,72 ans en 2006, 17,36 ans en 2008 et 28,0 ans en 2010, alors que les estimations de l'Organisation mondiale de la santé situent cet indicateur autour de 52 ans sur la période. Ces trois valeurs ont été neutralisées puis reconstruites par interpolation intra-pays.

3. Pre-processing et feature engineering

3.1 Imputation

Deux options ont été écartées avant de retenir la stratégie finale. La suppression des lignes incomplètes aurait fait perdre des pays entiers ou des années entières, ce qui est rédhibitoire pour un tableau de bord fondé sur la comparaison internationale et le suivi de tendances. L'imputation par la moyenne mondiale, quant à elle, ignore la structure de panel : attribuer à l'Afghanistan le PIB moyen mondial produirait une valeur sans rapport avec la trajectoire réelle du pays.

Passe	Méthode	Justification
1	Interpolation linéaire intra-pays	Préserve la trajectoire chronologique propre à chaque pays
2	Forward fill puis backward fill intra-pays	Traite les extrémités de série
3	Médiane globale	Dernier recours pour les pays dépourvus de toute donnée sur la colonne

La médiane a été préférée à la moyenne en troisième passe en raison de l'asymétrie marquée de plusieurs distributions. À l'issue des trois passes, le jeu ne contient plus aucune valeur manquante sur les 2 363 lignes.

Figure 6 — Distributions avant / après imputation




Figure 2 — Distributions avant et après imputation

La superposition des densités constitue le contrôle qualité de l'opération : les courbes restent quasi confondues pour les huit variables imputées. L'imputation a donc comblé les manquants sans déformer la structure statistique des données.

3.2 Normalisation et standardisation

Deux transformations ont été appliquées en parallèle, chacune répondant à un usage distinct, et conservées côte à côte dans le fichier final plutôt que substituées aux colonnes d'origine.

Transformation	Formule	Usage	Limite
Min-Max, suffixe _minmax	$(x - \min) / (\max - \min)$	Radars, heatmaps, jauges — 0 et 1 correspondent aux extrêmes mondiaux, lecture immédiate	Sensible aux extrêmes : un seul pays atypique étire toute l'échelle

Transformation	Formule	Usage	Limite
Z-score, suffixe _zscore	$(x - \mu) / \sigma$	Analyses statistiques, score composite — z = +2 signifie deux écarts-types au-dessus de la moyenne	Moins intuitif, valeurs non bornées

La cible life_ladder a délibérément été exclue des deux transformations : l'échelle de Cantril est directement interprétable par l'utilisateur final, et une valeur de 7,7 pour la Finlande parle davantage qu'un z-score de +1,97.

3.3 Variables créées

Variable	Construction	Apport
happiness_category	Découpage ordinal en 5 classes, seuils 3,5 / 5,0 / 6,0 / 7,0	Segmentation. Répartition : 3,3 % / 32,3 % / 30,6 % / 22,8 % / 11,1 %
life_ladder_yoy	Variation du score par rapport à l'année précédente, par pays	Détection des ruptures. 165 NaN volontaires, première année de chaque pays
net_affect	positive_affect – negative_affect	Solde émotionnel, r = +0,540 avec la cible
economic_wellbeing_score	$0,35 \times z(\text{PIB}) + 0,35 \times z(\text{soutien social}) + 0,30 \times z(\text{espérance de vie})$	Prédicteur de référence, r = +0,828 avec la cible

Le recours aux versions Z-score dans le score composite n'est pas neutre : il garantit que chaque composante contribue à hauteur de son poids déclaré et non de son amplitude d'origine. Construit sur les valeurs brutes, le score aurait été presque intégralement déterminé par l'espérance de vie, seule variable exprimée en dizaines d'unités.

4. Analyses et résultats

4.1 Distribution de la cible et évolution temporelle

Figure 3 — Variable cible : Life Ladder




Figure 3 — Distribution du Life Ladder et moyenne mondiale par année

La distribution du Life Ladder est remarquablement proche d'une loi normale : moyenne de 5,48, médiane de 5,45, skewness de $-0,05$. Cette quasi-symétrie autorise l'usage de tests paramétriques et de la corrélation de Pearson sans transformation préalable. L'étendue observée, de 1,28 à 8,02, occupe moins des deux tiers de l'échelle théorique : aucun pays ne se situe aux extrémités absolues.

La courbe d'évolution appelle une lecture prudente. Le décrochage apparent entre 2005, à 6,45, et 2006, à 5,20, ne traduit aucun phénomène réel : il correspond au passage de 27 à 89 pays enquêtés, l'échantillon initial étant composé de pays majoritairement développés. Une fois l'échantillon stabilisé à partir de 2007, la moyenne mondiale se révèle très stable, oscillant entre 5,39 et 5,73 sur seize ans.

4.2 Hiérarchie des facteurs

Figure 4 — Matrice de corrélation




Figure 4 — Matrice de corrélation

Variable	r avec Life Ladder	Lecture
Log GDP per capita	+0,784	Association très forte
Social support	+0,723	Association forte
Healthy life expectancy	+0,715	Association forte
Freedom to make life choices	+0,538	Association modérée
Positive affect	+0,515	Association modérée
Perceptions of corruption	-0,430	Association négative modérée
Negative affect	-0,352	Association négative faible
Generosity	+0,177	Association négligeable

Trois variables se détachent, toutes au-dessus de $r = +0,71$. Elles sont cependant fortement corrélées entre elles — un pays riche tend à disposer d'un meilleur système de santé — ce qui signifie qu'elles partagent une large part d'information commune.

Deux résultats méritent une attention particulière. Generosity est pratiquement décorrélée de la cible : construite comme le résidu d'une régression des dons sur le PIB, elle mesure précisément ce que la richesse n'explique pas, et son faible pouvoir explicatif est cohérent avec cette définition. Par ailleurs,

positive_affect et negative_affect ne sont pas les deux pôles d'un même axe : leurs corrélations avec la cible sont asymétriques, ce qui indique qu'un pays peut cumuler des niveaux élevés d'émotions positives et négatives.

4.3 Classement des pays




Figure 5 — Pays les mieux et les moins bien classés en 2023

Sur les 138 pays renseignés en 2023, la Finlande occupe la première place avec 7,70, devant l'Islande à 7,56 et le Danemark à 7,50. L'Afghanistan ferme le classement avec 1,45, très en retrait du Malawi à 3,27 qui le précède. L'écart entre les extrêmes atteint 6,25 points sur une échelle de 10, soit plus de cinq écarts-types.

4.4 Écarts au modèle




Figure 6 — Catégories, variation annuelle et score composite

Le nuage de points reliant le score composite à la cible affiche une relation linéaire nette, de coefficient $r = +0,828$, avec une dispersion résiduelle qui reste substantielle. À niveau économique et sanitaire équivalents, des écarts de plus d'un point subsistent entre pays. C'est ce constat qui a motivé la construction d'une analyse dédiée aux résidus, décrite en section 5.2.

La distribution de la variation annuelle est centrée sur zéro, de moyenne $+0,013$ et d'écart-type $0,389$, confirmant qu'à l'échelle mondiale les scores sont globalement stables. Ses queues sont néanmoins riches d'enseignements : en 2023, le Liban progresse de 1,24 point tandis qu'Israël recule de 0,88, deux mouvements directement rattachables au contexte géopolitique de l'année.

5. Restitution

5.1 Tableau de bord Power BI

Le tableau de bord comporte quatre pages, 40 visuels et 8 tables. Construit en deux itérations, il répond aux quatre questions d'entrée du projet : où en est le monde, qu'est-ce qui explique les écarts, où se situe tel pays, et qui échappe à la règle.




Figure 7 — Page Executive Overview

Page	Rôle	Visuels principaux
Executive Overview	État des lieux mondial	6 cartes KPI, courbe temporelle, carte géographique, Top 10
Drivers of Global Happiness	Analyse des facteurs	Nuage de points piloté par un paramètre de champ, matrice de corrélation interactive
Country Explorer	Consultation pays par pays	Radar sur les colonnes normalisées, comparaison chiffrée au monde, trajectoire, variations annuelles
Modèle de régression	Écarts au modèle économique	Score observé face au score attendu, coloration par écart, carte $r^2 = 0,75$

La page Modèle de régression est l'aboutissement de la démarche : elle croise le score composite construit au pre-processing et le score observé, matérialise le score attendu par une droite de tendance, et colore chaque pays selon son écart au modèle, de $-1,34$ à $+1,72$ sur la période complète. La carte r^2 affiche $0,75$: les conditions économiques et sanitaires expliquent les trois quarts de la variance du bien-être déclaré, et la page donne à voir le quart restant.

6. Difficultés rencontrées

6.1 Verrou principal

La difficulté centrale du projet n'a été ni technique ni méthodologique, mais interprétative. Les corrélations élevées entre le bien-être et les trois déterminants dominants s'établissent rapidement et ne posent aucun problème de calcul. Le verrou est ailleurs : ces trois variables étant fortement corrélées entre elles, il est impossible, avec ces seules données, d'attribuer à chacune une contribution propre. Un pays riche dispose d'un meilleur système de santé et d'un tissu social plus dense ; démêler ces effets exigerait des données que le rapport ne fournit pas.

Le contournement retenu consiste à ne pas chercher à isoler les contributions, mais à construire un prédicteur composite assumé, puis à concentrer l'analyse sur ce qu'il n'explique pas. Le déplacement de la question — non plus « qu'est-ce qui explique le bonheur » mais « qui s'écarte de ce que ses conditions laissent attendre » — s'est révélé plus fécond que la recherche d'une décomposition impossible.

6.2 Difficultés liées aux données

- Panel non équilibré : les années 2005 et 2006 reposent sur un échantillon de pays trop restreint et non représentatif, ce qui produit un décrochage apparent de la moyenne mondiale qu'il faut expliquer plutôt que masquer.
- Manquants non aléatoires sur Perceptions of corruption : l'absence de réponse porte elle-même une information, que l'imputation efface nécessairement.
- Anomalie de saisie sur l'espérance de vie d'Haïti, détectable uniquement par confrontation à une source externe.
- Absence de tout référentiel géographique dans la source, qui a nécessité la construction d'une table de correspondance.
- Encodage latin-1 non documenté, qui corrompt silencieusement certains noms de pays si la lecture ne le précise pas.

6.3 Difficultés de compétences

Trois compétences ont dû être acquises ou consolidées en cours de projet. La modélisation Power BI et le langage DAX, d'abord : la deuxième version du tableau de bord a exigé de dépasser le glisser-déposer pour construire des tables au format long, un paramètre de champ et des mesures statistiques, en s'appuyant sur les modules de la formation et la documentation Microsoft. Le traitement des données de panel, ensuite : l'imputation temporelle intra-pays ne figure pas dans les recettes standard et a demandé de comprendre pourquoi les méthodes globales étaient inadaptées à cette structure. La distinction entre normalisation et standardisation, enfin : savoir laquelle choisir selon l'usage — la visualisation pour le radar, le calcul pour le score composite — s'est révélée plus structurante que la mécanique des formules elle-même.

6.4 Difficultés techniques et organisationnelles

La principale difficulté d'organisation a tenu au format du fichier Power BI : un .pbix est un binaire qui ne se prête ni à la fusion ni au suivi de versions ligne à ligne, si bien qu'une seule personne pouvait modifier le tableau de bord à la fois. Le groupe a contourné la contrainte en séparant les rôles — préparation des données et tables de support d'un côté, construction des visuels de l'autre — et en faisant circuler le fichier avec un nommage daté. Le notebook, en revanche, étant un fichier texte, s'est partagé sans friction. L'autre

point de vigilance a été la cohérence entre le notebook et le tableau de bord : chaque évolution du fichier nettoyé devait être répercutée dans le modèle Power BI, ce qui a renforcé l'intérêt de centraliser tous les traitements en amont.

6.5 Écart au prévisionnel

Par rapport au planning initial, l'exploration et le nettoyage ont été plus rapides que prévu : le jeu de données est petit et bien documenté, et le taux de manquants faible. La restitution a en revanche pris davantage de temps qu'anticipé, pour une raison de fond plus que de technique : la première version du tableau de bord, purement descriptive, n'exploitait pas le travail de pre-processing, et il a fallu une seconde itération complète — restructuration du modèle, nouvelles tables, nouvelles mesures — pour y remédier. Une tâche s'est ajoutée en cours de route sans avoir été planifiée : la construction du référentiel géographique, rendue nécessaire par l'absence de codes ISO dans la source.

7. Bilan par objectif

Objectif	Atteint	Éléments de preuve
1 — Jeu de données propre et documenté	Oui	2 363 lignes conservées, 0 valeur manquante, 31 colonnes documentées dans le rapport d'exploration
2 — Hiérarchiser les facteurs	Oui	Hiérarchie établie du PIB (+0,784) à la générosité (+0,177) ; score composite validé à $r = +0,828$
3 — Dynamiques temporelles	Oui	Variable life_ladder_yoy exploitée dans le tableau de bord (histogramme des variations du Country Explorer) et dans l'application
4 — Restitution accessible	Oui	Tableau de bord Power BI à quatre pages, dont une dédiée aux écarts au modèle

7.1 Ce que le projet établit

Le bien-être déclaré est fortement associé à trois conditions matérielles : le revenu, la santé et la densité du lien social. Ce trio explique l'essentiel des écarts entre pays, avec un coefficient de corrélation de 0,828 pour le score composite qui les agrège.

Mais il ne l'explique pas entièrement, et c'est le résultat le plus intéressant. À conditions économiques et sanitaires comparables, des écarts de plus d'un point de Cantril subsistent. Le Costa Rica se classe très au-dessus de ce que son PIB laisserait attendre, le Botswana très en dessous. Ces résidus constituent la trace mesurable de facteurs que les six déterminants du rapport ne captent pas : culture, institutions, inégalités internes, situation politique.

7.2 Ce que le projet n'établit pas

- Aucune relation de causalité. Les corrélations mises en évidence sont des associations statistiques ; le sens de la causalité entre bien-être et développement économique n'est pas établi par ces données.
- Aucune contribution propre des trois déterminants dominants, en raison de leur forte corrélation mutuelle.
- Aucune analyse infranationale : les inégalités internes à un pays sont invisibles dans une moyenne nationale, alors qu'elles pèsent vraisemblablement sur le bien-être déclaré.
- Aucune validation de la comparabilité interculturelle de l'échelle de Cantril : rien ne garantit qu'un 7 déclaré au Japon recouvre la même réalité qu'un 7 déclaré au Mexique.

8. Suite du projet

Piste	Objet	Intérêt attendu
Analyse en composantes principales	Quantifier la redondance entre les trois déterminants dominants	Déterminer combien de dimensions indépendantes structurent réellement le jeu de données
Clustering des pays	Segmenter sur les variables standardisées	Faire émerger des profils de bien-être au-delà du classement linéaire
Analyse systématique des résidus	Croiser les écarts au modèle avec des variables externes	Tester les hypothèses culturelles et institutionnelles avancées en section 7.1
Enrichissement par des sources tierces	Coefficient de Gini, indice de démocratie, part du secteur informel	Réduire la part inexpliquée du modèle
Mise en ligne du tableau de bord	Publication sur Power BI Service	Rendre le livrable consultable sans installation

9. Conclusion

Ce projet est parti d'une intuition banale — l'argent ne fait pas le bonheur — pour la confronter à des données. Le résultat est nuancé. L'argent contribue au bonheur déclaré, et fortement : le PIB par habitant est la variable la plus corrélée à l'échelle de Cantril, devant toutes les autres. L'intuition populaire est donc partiellement démentie.

Mais elle n'est pas entièrement fausse pour autant. Une fois le revenu, la santé et le soutien social pris en compte, il reste des écarts considérables entre pays, et ces écarts ne sont pas du bruit : ils sont stables dans le temps et concernent toujours les mêmes pays. Le Costa Rica ne dépasse pas ses fondamentaux par accident.

D'un point de vue méthodologique, la leçon principale tient au pre-processing. Les décisions prises à cette étape — ne supprimer aucune ligne, imputer par pays plutôt que globalement, conserver deux mises à l'échelle en parallèle, laisser la cible sur son échelle d'origine — n'ont rien de spectaculaire prises isolément. Ce sont pourtant elles qui ont rendu possible chacune des analyses présentées ensuite. Une normalisation choisie au hasard aurait produit un radar illisible et un score composite dominé par une seule variable.

Au-delà du résultat analytique, le projet a laissé au groupe un enseignement de méthode : la valeur d'une analyse ne se joue pas dans la sophistication des outils mais dans la capacité à reformuler la question quand les données résistent. C'est en acceptant que les trois déterminants dominants ne se laissent pas décomposer que la question des écarts au modèle a émergé — et avec elle la partie la plus intéressante du travail. La seconde leçon est plus prosaïque mais tout aussi durable : chaque décision de pre-processing doit pouvoir se justifier par la restitution qu'elle rend possible, faute de quoi elle encombre le livrable au lieu de le servir.

Bibliographie

Sources de données

- Helliwell, J. F., Layard, R., Sachs, J. D., De Neve, J.-E., Aknin, L. B., Wang, S. (dir.), World Happiness Report 2024, Wellbeing Research Centre, University of Oxford. Consultable sur worldhappiness.report.
- Gallup World Poll — enquête annuelle source des variables déclaratives.
- Banque mondiale, indicateurs du développement dans le monde — PIB par habitant en parité de pouvoir d'achat, dollars internationaux constants 2017.
- Organisation mondiale de la santé, Global Health Observatory — espérance de vie en bonne santé à la naissance.
- Norme ISO 3166-1 alpha-3 — codes pays utilisés pour la construction du référentiel géographique.

Références méthodologiques

- Cantril, H., The Pattern of Human Concerns, Rutgers University Press, 1965 — origine de l'échelle d'auto-évaluation employée par le rapport.
- Documentation pandas — méthodes interpolate, ffill et bfill utilisées pour l'imputation.
- Documentation scikit-learn — MinMaxScaler et StandardScaler, principes de mise à l'échelle.
- Documentation Microsoft Power BI et référence du langage DAX.

Annexes

Annexe A — Description des fichiers

Fichier	Type	Contenu
data_preparation.ipynb	Notebook Jupyter	Chaîne complète : chargement, exploration, imputation, normalisation, feature engineering, export
World-happiness-report-updated_2024.csv	Données brutes	2 363 × 11, encodage latin-1
World-happiness-report-cleaned.csv	Données traitées	2 363 × 31, aucune valeur manquante
world-happiness-report-Dashboard.pbix	Power BI	4 pages, 40 visuels, 8 tables, mesures DAX dont Model r2 et Gap to model

Annexe B — Structure du notebook

Section	Contenu
1	Chargement et profilage : dimensions, types, doublons, valeurs manquantes, statistiques descriptives
2	Analyse des valeurs manquantes et détection des valeurs atypiques par la méthode IQR
3	Imputation en trois passes et contrôle qualité par superposition des densités
4	Typage, renommage en snake_case, normalisation Min-Max et standardisation Z-score
5	Création des quatre variables dérivées
6	Contrôles finaux et export du fichier nettoyé

Annexe C — Dictionnaire des colonnes du fichier nettoyé

Groupe	Nb	Colonnes
Identifiants	2	country, year
Variables originales	9	life_ladder, log_gdp_per_capita, social_support, healthy_life_expectancy, freedom, generosity, corruption, positive_affect, negative_affect
Normalisation Min-Max	8	Les huit variables explicatives, suffixe _minmax
Standardisation Z-score	8	Les huit variables explicatives, suffixe _zscore
Variables créées	4	happiness_category, life_ladder_yoy, net_affect, economic_wellbeing_score

Annexe D — Outils et environnement

Usage	Outil
Traitement des données	Python, pandas, numpy
Visualisation exploratoire	matplotlib, seaborn
Tableau de bord	Microsoft Power BI Desktop
Environnement de développement	Jupyter Notebook

Annexe E — Recours à des outils d'assistance

Le référentiel géographique (`referentiel_pays.csv`) ainsi que la mise en forme des rapports et du support de soutenance ont été réalisés avec l'assistance d'un outil de génération de code et de documents. Les spécifications fonctionnelles, le choix des visualisations et les partis pris méthodologiques — conservation des valeurs atypiques, imputation intra-pays, exclusion de la variable cible de la normalisation, construction et pondération du score composite — relèvent de décisions prises par l'équipe et documentées dans le présent rapport.