

Analyse du bien-être sur Terre

World Happiness Report

Rendu n° 1

Rapport d'exploration, de data visualisation et de pre-processing des données

Jeu de données : World-happiness-report-updated_2024.csv
2 363 observations · 165 pays · 2005 – 2023

Sana Oubella · Seydou Dabo · Leodomir Hakizimana · Raphaela Essombono Nkoudou

Promotion : [2026] · Date : [Août 26]

Sommaire

Sommaire.....	2
1. Introduction au projet	3
1.1 Contexte.....	3
1.2 Objectifs	3
2. Compréhension et manipulation des données.....	5
2.1 Cadre et volumétrie	5
2.2 Description des variables	5
2.3 Analyse des valeurs manquantes.....	6
2.4 Statistiques descriptives et détection des outliers	6
3. Pre-processing et feature engineering	9
3.1 Imputation des valeurs manquantes	9
3.2 Typage et normalisation des noms de colonnes.....	9
3.3 Normalisation et standardisation	10
3.4 Feature engineering.....	10
4. Visualisations et analyses statistiques	11
4.1 Distribution de la variable cible et évolution temporelle	11
4.2 Relations entre variables	11
4.3 Classement des pays.....	13
4.4 Variables créées	13
5. Bilan et perspectives.....	15
5.1 Livrable produit.....	15
5.2 Synthèse des décisions de traitement	15
5.3 Limites identifiées.....	15
5.4 Suite du projet	16

1. Introduction au projet

1.1 Contexte

Depuis 2012, le World Happiness Report publie chaque année un classement mondial du bien-être fondé sur les enquêtes du Gallup World Poll. Sa particularité est de ne pas mesurer la richesse d'un pays, mais la façon dont ses habitants évaluent eux-mêmes leur propre vie, sur une échelle de 0 à 10 dite échelle de Cantril. Ce score déclaratif est ensuite mis en regard de six déterminants objectifs ou semi-objectifs : le produit intérieur brut par habitant, le soutien social, l'espérance de vie en bonne santé, la liberté de choix, la générosité et la perception de la corruption.

L'intérêt de ce jeu de données tient à ce décalage récurrent entre richesse et bien-être déclaré : certains pays très riches se classent en deçà de pays bien plus pauvres, et inversement. Comprendre quelles combinaisons de facteurs expliquent ces écarts constitue le cœur du projet.

Du point de vue métier

Les indicateurs de bien-être sont aujourd'hui mobilisés bien au-delà du champ académique : organisations internationales pour l'évaluation des politiques publiques, collectivités pour le pilotage de leur attractivité, directions des ressources humaines pour les politiques de qualité de vie au travail. Savoir restituer un indicateur composite complexe à un public non technique, sans en trahir la construction, est une compétence directement transposable en entreprise.

Du point de vue technique

Le jeu de données est un panel non équilibré (pays × année) : cette structure impose des traitements spécifiques, notamment pour l'imputation, qui doit respecter la trajectoire temporelle propre à chaque pays plutôt que d'écraser l'information par des statistiques globales. Il présente en outre une forte hétérogénéité d'échelles entre variables, ce qui rend indispensable une étape de normalisation avant toute visualisation comparative. Ces deux caractéristiques en font un support d'apprentissage complet pour la chaîne exploration → nettoyage → pre-processing → data visualisation.

Du point de vue économique

Le rapport est régulièrement cité pour arbitrer entre croissance économique et politiques sociales. Quantifier la part de variance du bien-être expliquée par le PIB par rapport à celle expliquée par le soutien social ou la liberté de choix a une portée directe en matière de priorisation des dépenses publiques. Le jeu de données étant public et gratuit, le coût de production de l'analyse se limite au temps d'étude.

1.2 Objectifs

Le projet poursuit quatre objectifs :

- Constituer un jeu de données propre, complet et documenté, exploitable directement par un outil de visualisation.
- Identifier et hiérarchiser les facteurs statistiquement associés au niveau de bien-être déclaré.
- Mettre en évidence les dynamiques temporelles et les ruptures : effets de crise, progressions et régressions rapides.
- Restituer l'ensemble sous forme de visualisations interactives lisibles par un public non spécialiste.

Le présent rendu couvre les trois premières étapes de la chaîne de traitement : exploration, nettoyage et pre-processing, ainsi que les visualisations exploratoires qui les justifient. La conception du tableau de bord fera l'objet du rendu n° 2.

Aucun membre du groupe ne disposait d'une expertise préalable sur les indicateurs de bien-être : la compréhension du domaine s'est construite à partir de la documentation méthodologique du World Happiness Report, sans recours à un expert métier. Les nombreuses analyses publiques de ce jeu de données, presque toutes centrées sur le classement, ont conforté le choix d'orienter le projet vers les écarts entre le bien-être observé et celui que les conditions économiques laissent attendre.

2. Compréhension et manipulation des données

2.1 Cadre et volumétrie

Le jeu de données utilisé est le fichier `World-happiness-report-updated_2024.csv`, publié dans le cadre du World Happiness Report 2024 et diffusé librement sur Kaggle ainsi que sur le site officiel worldhappiness.report. Les données sont produites par le Gallup World Poll et enrichies de sources tierces publiques (Banque mondiale pour le PIB, Organisation mondiale de la santé pour l'espérance de vie). Aucune restriction d'usage n'y est attachée pour un projet pédagogique. Le fichier est encodé en latin-1, ce qui impose de le préciser explicitement à la lecture, faute de quoi certains noms de pays sont corrompus.

Caractéristique	Valeur
Nombre de lignes	2 363
Nombre de colonnes	11
Pays couverts	165
Période couverte	2005 à 2023, soit 19 années
Granularité	1 ligne = 1 pays × 1 année (structure de panel)
Clé primaire	(Country name, year) — 0 doublon strict, 0 doublon sur la clé
Valeurs manquantes	386 cellules, soit 1,49 % du total
Poids du fichier	≈ 160 Ko

Le panel est non équilibré : le nombre d'observations par pays varie de 1 (Cuba) à 18 (Argentine), pour une médiane de 16. La couverture s'étoffe progressivement dans le temps — 27 pays seulement en 2005, 89 en 2006, puis un plateau compris entre 116 et 147 pays à partir de 2007. Cette montée en charge a une conséquence directe sur l'interprétation : la moyenne mondiale de 2005 (6,45) est artificiellement élevée parce qu'elle ne porte que sur une trentaine de pays majoritairement développés, alors que la moyenne de 2006 chute à 5,20 dès l'élargissement de l'échantillon. Il ne s'agit pas d'un effondrement du bien-être mondial mais d'un biais d'échantillonnage, à neutraliser dans le tableau de bord.

2.2 Description des variables

Le fichier comporte deux identifiants et neuf variables quantitatives. Le tableau ci-dessous en donne une vue synthétique ; le détail complet, colonne par colonne, figure dans le rapport d'exploration des données joint au format tableur.

Variable	Description	Type	NA
Country name	Nom du pays enquêté (165 modalités)	object	0 %
year	Année de l'enquête (2005–2023)	int64	0 %
Life Ladder	Score de bien-être déclaré, échelle de Cantril — CIBLE	float64	0 %
Log GDP per capita	Log du PIB/habitant en PPA (USD constants 2017)	float64	1,18 %
Social support	Part pouvant compter sur un proche en cas de besoin	float64	0,55 %
Healthy life expectancy at birth	Espérance de vie en bonne santé, en années	float64	2,67 %
Freedom to make life choices	Satisfaction quant à la liberté de choix de vie	float64	1,52 %

Variable	Description	Type	NA
Generosity	Résidu de la régression des dons sur le PIB/habitant	float64	3,43 %
Perceptions of corruption	Corruption perçue dans le gouvernement et les entreprises	float64	5,29 %
Positive affect	Fréquence des émotions positives ressenties la veille	float64	1,02 %
Negative affect	Fréquence des émotions négatives ressenties la veille	float64	0,68 %

2.3 Analyse des valeurs manquantes

Le taux global de valeurs manquantes est faible : 386 cellules sur 25 993, soit 1,49 %. Deux constats orientent la stratégie de traitement. D'abord, la variable cible Life Ladder ainsi que les deux identifiants sont intégralement renseignés : aucune observation n'est donc à écarter pour cause de cible absente. Ensuite, les manquants sont très inégalement répartis entre variables.

Figure 1 — Analyse des valeurs manquantes




Figure 1 — Taux de valeurs manquantes par variable et localisation dans le jeu de données

Perceptions of corruption concentre à elle seule un tiers des manquants (5,29 % de la colonne). Ce n'est pas un hasard : la question porte sur un sujet politiquement sensible et n'est pas posée, ou reste sans réponse exploitable, dans certains pays. Le mécanisme de manquant n'est donc pas aléatoire (MNAR) et l'imputation de cette colonne doit être interprétée avec prudence. La heatmap de droite montre par ailleurs que les manquants se regroupent par blocs horizontaux, c'est-à-dire par pays, et non de façon diffuse : un pays donné tend à être absent d'une variable sur plusieurs années consécutives. Ce constat plaide directement pour une imputation intra-pays plutôt que globale.

2.4 Statistiques descriptives et détection des outliers

La méthode de l'écart interquartile (IQR) a été appliquée à chaque variable numérique : une valeur est considérée comme atypique si elle sort de l'intervalle $[Q1 - 1,5 \times IQR ; Q3 + 1,5 \times IQR]$.

Variable	Min	Médiane	Max	Écart-type	Skewness	Outliers
Life Ladder	1,281	5,449	8,019	1,126	-0,05	2 (0,08 %)
Log GDP per capita	5,527	9,503	11,676	1,152	-0,34	1 (0,04 %)
Social support	0,228	0,834	0,987	0,121	-1,11	48 (2,03 %)
Healthy life expectancy	6,720	65,100	74,600	6,843	-1,13	20 (0,85 %)

Variable	Min	Médiane	Max	Écart-type	Skewness	Outliers
Freedom to make life choices	0,228	0,771	0,985	0,139	-0,70	16 (0,68 %)
Generosity	-0,340	-0,022	0,700	0,161	+0,77	39 (1,65 %)
Perceptions of corruption	0,035	0,798	0,983	0,185	-1,49	194 (8,21 %)
Positive affect	0,179	0,663	0,884	0,106	-0,46	9 (0,38 %)
Negative affect	0,083	0,262	0,705	0,087	+0,70	31 (1,31 %)

Figure 2 — Boxplots des variables numériques (détection des outliers)




Figure 2 — Boxplots des neuf variables numériques

Deux enseignements ressortent de ces statistiques. Le premier concerne les échelles : l'espérance de vie en bonne santé s'exprime en années et couvre l'intervalle [6,7 ; 74,6], le log-PIB varie entre 5,5 et 11,7, tandis que les six autres indicateurs sont des proportions bornées dans [0 ; 1]. Un facteur cent sépare les amplitudes ; sans mise à l'échelle, l'espérance de vie écraserait mécaniquement toutes les autres variables dans un graphique radar, une heatmap ou tout algorithme fondé sur des distances. C'est ce constat, et lui seul, qui justifie l'étape de normalisation décrite en section 3.

Le second concerne les valeurs atypiques. Perceptions of corruption en compte 194, soit 8,21 % : un taux qui pourrait alarmer, mais qui traduit en réalité la forme très asymétrique de sa distribution (skewness = -1,49, valeurs massivement concentrées au-dessus de 0,70) plutôt que des erreurs de mesure. La méthode IQR suppose une distribution approximativement symétrique et sur-signe mécaniquement les distributions fortement dissymétriques.

Décision : conserver les outliers

Les valeurs extrêmes de ce jeu de données ne sont pas des artefacts mais des observations réelles : l'Afghanistan à 1,45 sur l'échelle de Cantril en 2023, ou le Burundi sur le soutien social, décrivent des situations authentiques. Les supprimer reviendrait à retirer de l'analyse précisément les pays les plus intéressants à comparer, et biaiserait tout classement. Les outliers sont donc intégralement conservés.

Exception : anomalie avérée sur Haïti

Un seul cas relève de l'erreur de saisie à la source. L'espérance de vie en bonne santé d'Haïti est renseignée à 6,72 ans en 2006, 17,36 ans en 2008 et 28,0 ans en 2010, alors que les estimations de l'OMS situent cet indicateur autour de 52 ans sur la période. Ces trois valeurs sont incohérentes avec les autres années du même pays et ont été neutralisées puis reconstruites par interpolation intra-pays.

3. Pre-processing et feature engineering

3.1 Imputation des valeurs manquantes

Deux options simples ont été écartées avant de retenir la stratégie finale. La suppression des lignes incomplètes aurait fait perdre des pays entiers ou des années entières, dégradant la couverture géographique et temporelle — rédhibitoire pour un tableau de bord dont l'intérêt repose justement sur la comparaison internationale et le suivi de tendances. L'imputation par la moyenne mondiale, quant à elle, ignore la structure de panel : attribuer à l'Afghanistan le PIB moyen mondial produirait une valeur sans rapport avec la trajectoire réelle du pays.

La stratégie retenue procède en trois passes successives, appliquées colonne par colonne :

Passe	Méthode	Justification
1	Interpolation linéaire intra-pays	Préserve la trajectoire chronologique propre à chaque pays ; méthode la plus fidèle pour un panel temporel
2	Forward fill puis backward fill intra-pays	Traite les extrémités de série, que l'interpolation ne peut pas encadrer
3	Médiane globale	Dernier recours pour les pays dépourvus de toute donnée sur la colonne

La médiane a été préférée à la moyenne en troisième passe en raison de l'asymétrie marquée de plusieurs distributions, en particulier Perceptions of corruption (skewness = -1,49) et Generosity (+0,77), pour lesquelles la moyenne est tirée par les valeurs extrêmes. À l'issue des trois passes, le jeu ne contient plus aucune valeur manquante sur les 2 363 lignes.

Figure 6 — Distributions avant / après imputation




Figure 3 — Distributions avant et après imputation (comparaison des densités)

La superposition des densités avant et après traitement constitue le contrôle qualité de l'opération : les courbes restent quasi confondues pour les huit variables imputées. L'imputation a donc comblé les manquants sans déformer la structure statistique des données, ce qui était l'objectif recherché.

3.2 Typage et normalisation des noms de colonnes

Les types ont été fixés explicitement (year en entier, les neuf indicateurs en flottant) et les colonnes renommées en snake_case, en abrégant les libellés les plus longs : Healthy life expectancy at birth devient healthy_life_expectancy, Freedom to make life choices devient freedom, Perceptions of corruption devient

corruption. Cette normalisation supprime les espaces et les majuscules, sources d'erreurs récurrentes lors de l'import dans les outils de visualisation, et raccourcit les libellés affichés dans les légendes.

3.3 Normalisation et standardisation

Comme établi en section 2.4, l'hétérogénéité des échelles interdit toute comparaison directe entre variables. Deux transformations ont été appliquées en parallèle, chacune répondant à un usage distinct, et conservées côte à côte dans le fichier final plutôt que substituées aux colonnes d'origine.

Transformation	Formule	Usage visé	Limite
Min-Max, suffixe _minmax	$(x - \min) / (\max - \min)$	Visualisations comparatives : radars, heatmaps, jauges du tableau de bord. 0 = minimum mondial, 1 = maximum mondial — lecture immédiate	Sensible aux extrêmes : un seul pays atypique étire toute l'échelle
Z-score, suffixe _zscore	$(x - \mu) / \sigma$	Analyses statistiques, ACP, clustering, construction du score composite. $z = +2$ signifie deux écarts-types au-dessus de la moyenne mondiale	Moins intuitif pour un public non technique ; valeurs non bornées

Les huit indicateurs explicatifs ont été transformés selon les deux méthodes, soit seize colonnes supplémentaires. La cible `life_ladder` a délibérément été exclue des deux transformations : l'échelle de Cantril est directement interprétable par l'utilisateur final, et une valeur de 7,7 pour la Finlande parle davantage qu'un z-score de +1,97.

3.4 Feature engineering

Quatre variables ont été créées afin d'enrichir les possibilités d'analyse et de filtrage :

Variable créée	Construction	Apport
<code>happiness_category</code>	Découpage ordinal de <code>life_ladder</code> en 5 classes aux seuils 3,5 / 5,0 / 6,0 / 7,0	Filtre de segmentation pour le tableau de bord. Répartition : 3,3 % très malheureux, 32,3 % malheureux, 30,6 % modérément heureux, 22,8 % heureux, 11,1 % très heureux
<code>life_ladder_yoy</code>	Différence du score par rapport à l'année précédente, calculée par pays	Détection des progressions et régressions rapides et des effets de choc. 165 NaN volontaires (première année observée de chaque pays)
<code>net_affect</code>	<code>positive_affect</code> – <code>negative_affect</code>	Solde émotionnel, complémentaire de l'évaluation cognitive mesurée par <code>life_ladder</code> ($r = +0,540$)
<code>economic_wellbeing_score</code>	$0,35 \times z(\log_gdp) + 0,35 \times z(\text{social_support}) + 0,30 \times z(\text{healthy_life_expectancy})$	Score composite des trois déterminants les plus corrélés à la cible. Corrélation avec <code>life_ladder</code> : $r = +0,828$, ce qui valide la pertinence de la pondération

Le recours aux versions Z-score dans le score composite n'est pas neutre : il garantit que chaque composante contribue à hauteur de son poids déclaré et non de son amplitude d'origine. Construit sur les valeurs brutes, le score aurait été presque intégralement déterminé par l'espérance de vie, seule variable exprimée en dizaines d'unités.

4. Visualisations et analyses statistiques

4.1 Distribution de la variable cible et évolution temporelle

Figure 3 — Variable cible : Life Ladder




Figure 4 — Distribution du Life Ladder et évolution de la moyenne mondiale (2005–2023)

La distribution du Life Ladder est remarquablement proche d'une loi normale : moyenne de 5,48, médiane de 5,45, skewness de $-0,05$. Cette quasi-symétrie est une bonne nouvelle méthodologique, car elle autorise l'usage de tests paramétriques et de la corrélation de Pearson sans transformation préalable de la cible. L'étendue observée, de 1,28 à 8,02, occupe moins des deux tiers de l'échelle théorique de 0 à 10 : aucun pays ne se situe aux extrémités absolues, ce qui invite à cadrer les axes du tableau de bord sur la plage réellement occupée plutôt que sur $[0 ; 10]$.

La courbe d'évolution appelle une lecture prudente. Le décrochage apparent entre 2005 (6,45) et 2006 (5,20) ne traduit aucun phénomène réel : il correspond au passage de 27 à 89 pays enquêtés, l'échantillon initial étant composé de pays majoritairement développés. Une fois l'échantillon stabilisé à partir de 2007, la moyenne mondiale se révèle très stable, oscillant entre 5,39 et 5,73 sur seize ans. Cette stabilité globale masque toutefois des trajectoires nationales très contrastées, que la variable `life_ladder_yoy` permet précisément d'isoler.

4.2 Relations entre variables

Figure 4 — Matrice de corrélation




Figure 5 — Matrice de corrélation des variables numériques

Les corrélations linéaires avec la variable cible se hiérarchisent nettement :

Variable	r avec Life Ladder	Lecture
Log GDP per capita	+0,784	Association très forte
Social support	+0,723	Association forte
Healthy life expectancy	+0,715	Association forte
Freedom to make life choices	+0,538	Association modérée
Positive affect	+0,515	Association modérée
Perceptions of corruption	-0,430	Association négative modérée
Negative affect	-0,352	Association négative faible
Generosity	+0,177	Association négligeable

Trois variables se détachent : le PIB par habitant, le soutien social et l'espérance de vie en bonne santé, toutes trois au-dessus de $r = +0,71$. Ce sont elles qui fondent le score composite `economic_wellbeing_score`, dont la corrélation avec la cible atteint $r = +0,828$, supérieure à celle de chacune de ses composantes prise isolément. Ces trois déterminants sont cependant fortement corrélés entre eux — un pays riche tend à disposer d'un meilleur système de santé — ce qui signifie qu'ils partagent

une large part d'information commune. Une analyse en composantes principales, envisagée pour le rendu n° 2, permettrait d'en quantifier la redondance.

Deux résultats méritent une attention particulière. D'une part, Generosity est pratiquement décorrélée de la cible ($r = +0,177$) : construite comme le résidu d'une régression des dons sur le PIB, elle mesure précisément ce que la richesse n'explique pas, et son faible pouvoir explicatif est cohérent avec cette définition. D'autre part, positive_affect et negative_affect ne sont pas les deux pôles d'un même axe : leurs corrélations avec la cible sont asymétriques (+0,515 contre -0,352), ce qui indique qu'un pays peut cumuler des niveaux élevés d'émotions positives et négatives. C'est ce qui justifie de les combiner en un solde net_affect plutôt que de n'en retenir qu'une.

4.3 Classement des pays




Figure 6 — Pays les mieux et les moins bien classés en 2023

Sur les 138 pays renseignés en 2023, la Finlande occupe la première place avec 7,70, devant l'Islande (7,56) et le Danemark (7,50) ; l'Afghanistan ferme le classement avec 1,45, très en retrait du Malawi (3,27) qui le précède. L'écart entre les extrêmes atteint 6,25 points sur une échelle de 10, soit plus de cinq écarts-types. Deux cas s'écartent du schéma dominant et méritent d'être exploités dans le tableau de bord : le Costa Rica (7,38, 4^e rang mondial) se classe très au-dessus de ce que son PIB par habitant laisserait attendre, tandis que le Botswana (3,33) fait l'inverse. Ces écarts entre score observé et score prédit par les déterminants économiques sont précisément ce que le projet cherche à mettre en évidence.

4.4 Variables créées




Figure 7 — Catégories de bonheur, variation annuelle et score composite

La segmentation ordinale montre une concentration des observations dans les classes intermédiaires : près des deux tiers du panel se répartissent entre les catégories « malheureux » (32,3 %) et « modérément

heureux » (30,6 %), tandis que les extrêmes restent peu peuplés (3,3 % et 11,1 %). La distribution de la variation annuelle est centrée sur zéro (moyenne = +0,013, écart-type = 0,389), confirmant qu'à l'échelle mondiale les scores sont globalement stables d'une année sur l'autre. Les queues de cette distribution sont néanmoins riches d'enseignements : en 2023, le Liban progresse de +1,24 point tandis qu'Israël recule de -0,88, deux mouvements directement rattachables au contexte géopolitique de l'année.

Le nuage de points reliant le score composite à la cible affiche une relation linéaire nette ($r = +0,828$), avec une dispersion résiduelle qui reste substantielle : à niveau économique et sanitaire équivalent, des écarts de plus d'un point subsistent entre pays. C'est dans cette dispersion résiduelle que se logent les facteurs culturels, institutionnels et politiques que les six déterminants du rapport ne captent pas.

5. Bilan et perspectives

5.1 Livrable produit

Le fichier World-happiness-report-cleaned.csv constitue le livrable technique de ce rendu. Il compte 2 363 lignes — aucune observation n'a été perdue — et 31 colonnes réparties comme suit :

Groupe	Nombre	Détail
Identifiants	2	country, year
Variables originales nettoyées	9	life_ladder et les huit indicateurs, renommés en snake_case
Normalisation Min-Max	8	Suffixe _minmax — destinées aux visualisations
Standardisation Z-score	8	Suffixe _zscore — destinées aux analyses statistiques
Variables créées	4	happiness_category, life_ladder_yoy, net_affect, economic_wellbeing_score
Total	31	—

5.2 Synthèse des décisions de traitement

Décision	Justification
Aucune ligne supprimée	Préservation de la couverture géographique et temporelle, indispensable à un tableau de bord comparatif
Imputation intra-pays en priorité	Respect de la structure de panel et des trajectoires nationales
Médiane plutôt que moyenne en dernier recours	Robustesse face aux distributions fortement asymétriques
Min-Max et Z-score conservés en parallèle	Deux usages distincts : restitution visuelle d'un côté, calcul statistique de l'autre
life_ladder laissé sur son échelle d'origine	Interprétabilité directe par l'utilisateur final
Outliers conservés	Valeurs réelles décrivant des situations authentiques, non des erreurs de mesure
Haïti 2006–2010 corrigé	Seule anomalie avérée, incompatible avec les données OMS

5.3 Limites identifiées

- Panel non équilibré : les années 2005 et 2006 reposent sur un échantillon de pays trop restreint et non représentatif pour être comparées aux années suivantes.
- Manquants non aléatoires sur Perceptions of corruption : l'absence de réponse est elle-même porteuse d'information, ce que l'imputation efface.
- Aucune variable de région ni de code ISO dans la source : une table de correspondance externe devra être jointe pour produire des cartes et des agrégats régionaux.
- Generosity, définie comme un résidu de régression, reste difficile à expliquer à un public non technique et devra être accompagnée d'une note de lecture.
- Les corrélations mises en évidence sont des associations et non des relations causales ; le sens de la causalité entre bien-être et développement économique n'est pas établi par ces données.

5.4 Suite du projet

Le rendu n° 2 portera sur les visualisations avancées et la conception du tableau de bord. Les pistes envisagées à ce stade sont l'ajout d'un référentiel géographique pour les cartes choroplèthes, une analyse en composantes principales destinée à quantifier la redondance entre les trois déterminants dominants, un clustering des pays sur les variables standardisées afin de faire émerger des profils de bien-être, et enfin l'analyse systématique des écarts entre score observé et score prédit par le score composite — ces écarts constituant la piste la plus prometteuse pour répondre à la question initiale du projet : pourquoi certains pays sont-ils mieux classés que ne le laisseraient prévoir leurs indicateurs économiques ?